Universidad Argentina de la Empresa (UADE)
Ciencia de Datos — Trabajo Práctico Obligatorio

Cine y videojuegos en Argentina

¿Quienes juegan videojuegos van más al cine? Un análisis de la Encuesta Nacional de Consumos Culturales 2022/23

Integrantes

Escudero, Morena. L.U.: 1218480

Fredes, Augusto. L.U.: 1133080

Gonzalez, Juan Ignacio. L.U.: 1170833

Gonzalez R., Matías. L.U.: 1166442

Uanin, Uriel. L.U.: 1132235

Noviembre de 2026

Resumen

Quienes juegan videojuegos en PC o consola van más al cine que quienes no juegan, y la diferencia se sostiene a igual edad y perfil socioeconómico: **+16,5 puntos porcentuales** (IC 95%: 9,9 a 23,1). Usamos los microdatos de la Encuesta Nacional de Consumos Culturales (ENCC) 2022/23, con 3.380 personas, y los estrenos comerciales del INCAA 2022–2023 (899 películas, 74,5 millones de entradas) enriquecidos con TMDB.

La estimación respeta el diseño muestral de la encuesta (ponderadores, estratos y conglomerados), y el resultado es estable en ocho variantes del análisis (odds ratio entre 2,23 y 2,56). En cambio, no encontramos diferencias en los géneros vistos en el cine: ninguno de los 10 resiste la corrección por comparaciones múltiples. Para predecir quién va al cine, el gaming no agrega información a la demografía (ΔAUC −0,006); el consumo de streaming sí (+0,048). El mejor modelo es una regresión logística con AUC 0,76.

Resumen **1**
1. Introducción **3**
2. Fuentes de datos **3**
3. Preparación y transformación de los datos **4**
4. Metodología **5**
4.1 Diseño muestral 5
4.2 Explicación: regresión logística 6
4.3 Robustez 6
4.4 Predicción 6
5. Resultados **7**
5.1 Quiénes juegan y cuánto van al cine 7
5.2 La diferencia a igual perfil (H1) 7
5.3 Robustez 8
5.4 Géneros vistos en el cine (H2) 8
5.5 Predicción 9
5.6 Contexto de mercado 10
6. Discusión y conclusiones **11**
7. Limitaciones **11**
8. Reproducibilidad **12**
Referencias **12**

1. Introducción

El trabajo indaga si jugar videojuegos se asocia con ir al cine en Argentina y si esa asociación sobrevive cuando se descuenta la edad. La pregunta tiene interés práctico: las adaptaciones de videojuegos ocupan un lugar creciente en la cartelera y, si los jugadores fueran un público distinto, serían un segmento a considerar.

Las preguntas de investigación son:

1. ¿Quienes juegan en PC o consola van más al cine que quienes juegan solo en el celular o no juegan?
2. ¿Esa diferencia se sostiene al comparar personas de la misma edad y nivel socioeconómico?
3. Entre quienes fueron al cine, ¿difieren los géneros que vieron?
4. Si ya conocemos el perfil demográfico de una persona, ¿saber si juega ayuda a predecir si va al cine?

Tabla 1. Hipótesis de partida.

	Hipótesis	**Cómo se evalúa**
H1	Los jugadores de PC/consola van más al cine, a igual edad y perfil	Regresión logística con diseño muestral
H2	Prefieren Acción, Ciencia ficción y Terror	Contrastes por género entre asistentes, con corrección de Holm
H3	Una campaña dirigida a ellos rinde más	No evaluable con estos datos (ver Limitaciones)

Como pregunta exploratoria adicional, evaluamos si el gaming mejora la predicción de la asistencia al cine.

2. Fuentes de datos

El análisis individual se basa en una sola fuente oficial, la ENCC 2022/23. INCAA y TMDB aportan contexto de mercado agregado y no se cruzan persona a persona con la encuesta.

Tabla 2. Fuentes utilizadas.

Fuente	**Qué aporta**	**Tamaño**	**Estado**
ENCC 2022/23 (SInCA, Secretaría de Cultura)	Consumos culturales por persona: cine, videojuegos, streaming, demografía	3.380 personas × 548 variables	Microdatos originales, sin editar

Fuente	Qué aporta	Tamaño	Estado
Cuestionario, metodología y diseño muestral ENCC	Universo de cada pregunta, saltos, diseño de la muestra	3 documentos PDF	Documentos oficiales
INCAA, estrenos comerciales 2022–2023	Entradas por película y fecha de estreno	899 estrenos, 74,5 millones de entradas	Derivado de un export de Tableau
TMDB	Géneros de catálogo por película	899 filas	Snapshot; la API no se vuelve a consultar

Universo. Personas de 13 años o más en localidades urbanas de más de 30.000 habitantes: 50 localidades en 7 regiones, que representan a 29,5 millones de personas. El trabajo de campo se realizó entre noviembre de 2022 y enero de 2023.

Integridad. Cada uno de los seis archivos de entrada tiene registrado su hash SHA-256, junto con la URL y la fecha de descarga. El pipeline verifica los hashes antes de ejecutarse y se detiene si alguno no coincide. También controla que los identificadores sean únicos, que los ponderadores sean positivos (0,03 a 28,41) y que todas las edades sean de 13 años o más.

Cobertura de TMDB. El 97% de las entradas vendidas corresponde a películas con un match confiable en TMDB (407 títulos). Los 335 títulos con menos de 1.000 entradas no se buscaron; suman el 0,2% de la taquilla.

3. Preparación y transformación de los datos

La limpieza parte de los microdatos sin editar y produce una base analítica con un diccionario de variables. Cada decisión queda registrada junto con la cantidad de casos afectados.

Mapeos estrictos. Cada etiqueta original se traduce mediante un mapeo explícito. Si aparece una etiqueta no prevista, el proceso falla en lugar de asignarla en silencio.

Salto estructural frente a no respuesta. El cuestionario hace ciertas preguntas solo a una parte de la muestra. Se distinguen tres casos:

- **Cero estructural:** quien no jugó tiene 0 en dispositivos y géneros de juego (2.482 personas). Es una respuesta verdadera, no una imputación. Lo mismo vale para el streaming entre quienes no usan plataformas (1.258 personas).
- **Fuera del universo:** los géneros vistos en el cine solo existen para quien fue al cine; para las otras 2.242 personas quedan vacíos.
- **Ns/Nc:** queda vacío, sin imputar.

Un control automático verifica, pregunta por pregunta, que solo haya datos dentro del universo definido por el cuestionario. No se encontraron inconsistencias.

Correcciones respecto de la primera versión del trabajo. La revisión de la limpieza anterior encontró tres errores que alteraban los resultados:

Tabla 3. Errores corregidos en la limpieza.

Variable	Error	Casos
Ocupado	Buscar la subcadena «trabaj» marcaba como ocupadas también las respuestas «No trabaja…»	1.389
Géneros de videojuego	Las etiquetas estaban corridas un lugar respecto de los códigos V328–V339 (Puzzle figuraba como «novela visual»); se reasignaron por código de variable	Todas las columnas
Géneros vistos en el cine	Se completaban con 0 para quien no fue, por lo que la «preferencia» medía en realidad asistencia	2.242

Además, se dejó de imputar «secundario completo» a quienes no informaron su nivel educativo.

Segmentos. Las personas se clasifican según los dispositivos que usaron para jugar en el último año: *PC/consola* (consola, PC de escritorio o notebook; 452 personas, 18% de la población), *solo móvil* (celular o tablet; 445 personas, 15%) y *no juega* (2.482 personas, 67%). Un jugador sin dispositivo declarado queda sin segmento.

4. Metodología

Se usaron dos técnicas porque las preguntas son dos. Para *explicar* (si la diferencia es real o solo refleja la edad) se usó regresión logística con diseño muestral. Para *predecir* (si el gaming aporta información) se compararon regresión logística y Random Forest sobre un conjunto de test reservado.

4.1 Diseño muestral

La ENCC está estratificada por región, y su primera etapa de muestreo son las localidades. Tratarla como una muestra aleatoria simple subestimaría la incertidumbre. Por eso se usa el ponderador para proporciones y modelos, y el expansor solo para totales de población. La varianza se calcula por linealización de Taylor, con estrato = región y unidad primaria = localidad (43 grados de libertad), el mismo estimador que svyglm en R. La dispersión de los ponderadores reduce el tamaño efectivo de la muestra de 3.380 a unas 1.500 personas (efecto de diseño 2,25).

4.2 Explicación: regresión logística

El desenlace es haber ido al cine en el último año (sí/no). Se estimó una regresión logística ponderada, sin regularización, con errores estándar que respetan el diseño muestral. La implementación se validó contra statsmodels, con coeficientes idénticos. Antes de estimar se fijaron tres especificaciones:

1. **Cruda:** solo el segmento de juego.
2. **Edad + NSE:** se agregan un spline de edad y el nivel socioeconómico.
3. **Completa:** se suman género, educación, actividad, región y tamaño de la localidad.

Se reportan odds ratios y, sobre todo, **probabilidades ajustadas** por estandarización marginal: la asistencia esperada si toda la población perteneciera a un segmento, manteniendo su perfil real. Las diferencias se expresan en puntos porcentuales (pp), con intervalos por el método delta. Para los géneros se compara solo a quienes fueron al cine; los 10 géneros forman una familia de contrastes, cuyos p-valores se corrigen por el método de Holm.

4.3 Robustez

El modelo principal se repitió en ocho variantes: sin ponderar, con varianza sin estratos y sin diseño, con la especificación de la primera versión, solo entre 13 y 49 años, con ponderadores recortados y con el segmento definido sin notebook.

4.4 Predicción

- **Objetivo:** clasificar si la persona fue al cine. Se excluyen todas las preguntas del bloque de cine para evitar fuga de información (*leakage*).
- **Partición:** 80/20 estratificada (2.704 / 676 casos), con semilla fija. El test se usa una sola vez, al final.
- **Selección de hiperparámetros:** validación cruzada estratificada 5 × 3, solo en entrenamiento. Imputación, escalado y codificación one-hot se ajustan dentro de cada partición (Pipeline de scikit-learn).
- **Bloques acumulativos de variables:** demografía → + segmento de juego → + gaming completo → + streaming. Comparar los bloques mide cuánto aporta cada fuente de información.
- **Modelos:** baseline (siempre «no va»), regresión logística y Random Forest.
- **Métricas ponderadas:** ROC-AUC, PR-AUC, Brier, precisión, recall, F1 y matriz de confusión. El umbral de clasificación se elige en entrenamiento, maximizando F1.
- **Incertidumbre:** bootstrap por localidad (2.000 réplicas), también para las diferencias de AUC entre bloques. La importancia de las variables se mide por permutación en el test.

5. Resultados

5.1 Quiénes juegan y cuánto van al cine

El 36% de la población fue al cine en el último año, pero la proporción cambia mucho según el segmento: 62% entre quienes juegan en PC/consola, 45% entre quienes juegan solo en el celular y 27% entre quienes no juegan. Los segmentos tienen perfiles muy distintos. Quien juega en PC/consola tiene en promedio 26 años, y el 70% es menor de 30. Quien no juega tiene en promedio 48 años. Como los jóvenes van más al cine, la comparación directa mezcla el efecto de jugar con el de la edad.

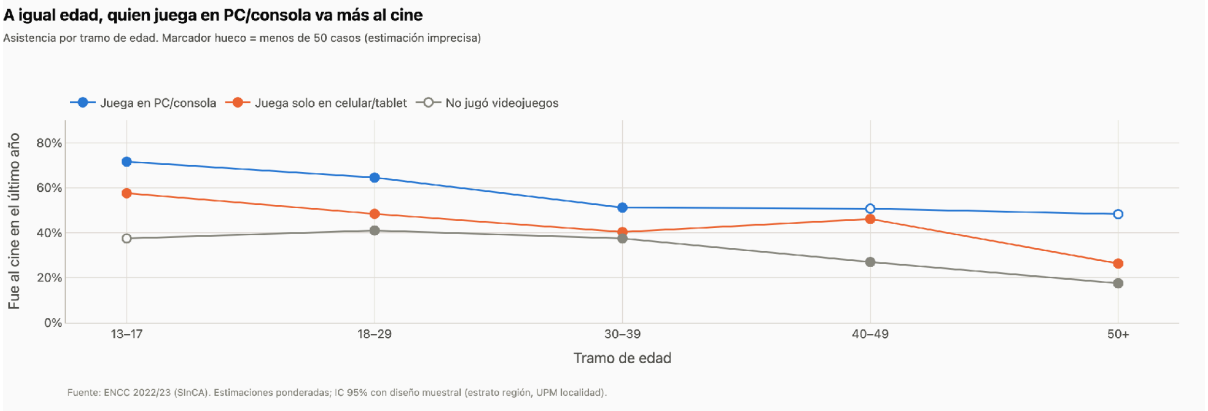


Figura 1. Asistencia al cine por edad y segmento. Fuente: ENCC 2022/23, elaboración propia.

5.2 La diferencia a igual perfil (H1)

Al ajustar, la brecha entre PC/consola y no juega se reduce a menos de la mitad, pero no desaparece.

Tabla 4. Diferencia en la asistencia al cine entre PC/consola y no juega, según especificación.

Especificación	Diferencia	IC 95%	Odds ratio (IC 95%)
Cruda	+35,1 pp	29,6 a 40,5	4,43 (3,48–5,62)
Edad + NSE	+18,1 pp	12,6 a 23,6	2,35 (1,81–3,04)
Completa	+16,5 pp	9,9 a 23,1	2,29 (1,66–3,14)

La edad y el nivel socioeconómico explican casi la mitad de la diferencia; las demás variables cambian poco. Con el ajuste completo, quien juega solo en el celular también va más al cine que quien no juega (+8,4 pp; IC 3,8 a 13,1), y quien juega en PC/consola va más que quien juega solo en el celular (+8,1 pp; IC 2,1 a 14,0). El orden de los tres grupos se mantiene.

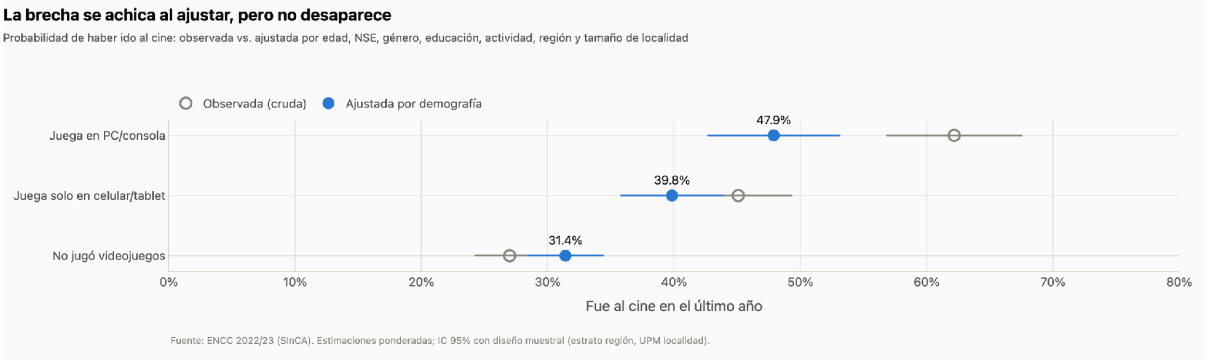


Figura 2. Asistencia observada y ajustada por demografía, por segmento. Fuente: ENCC 2022/23, elaboración propia.

5.3 Robustez

El odds ratio queda entre 2,23 y 2,56 en las ocho variantes, y el límite inferior más bajo de todos los intervalos es 1,62. Ninguna decisión de análisis cambia la conclusión.

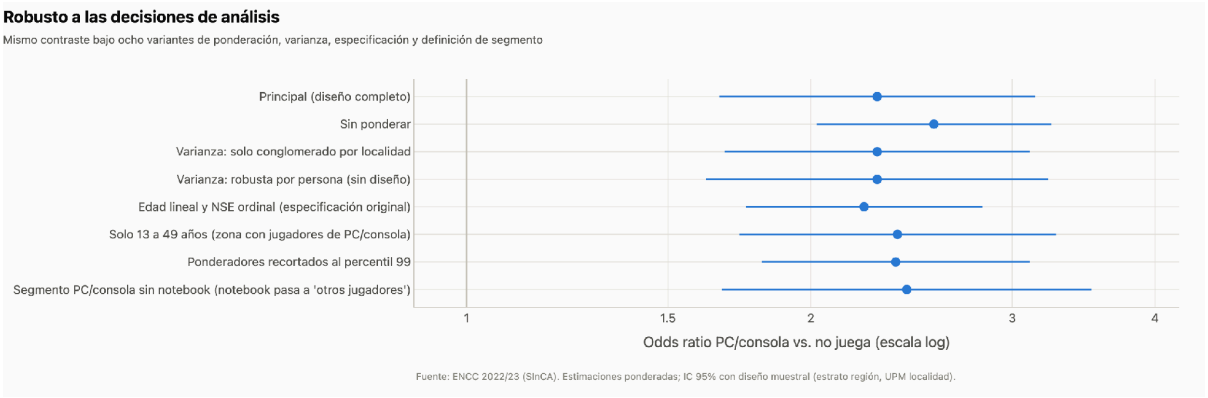


Figura 3. Odds ratio PC/consola vs. no juega en las variantes de sensibilidad. Fuente: ENCC 2022/23, elaboración propia.

5.4 Géneros vistos en el cine (H2)

Ninguno de los 10 géneros muestra una diferencia significativa entre PC/consola y no juega después de la corrección de Holm (1.136 asistentes). El único p-valor nominal por debajo de 0,05 es el de Comedia ($p = 0,043$), y va en la dirección contraria a la hipótesis: los jugadores la ven menos. Corregido por Holm, $p = 0,43$.

La diferencia que encontraba la primera versión era un artefacto de medición, como muestra el caso de Acción/Aventura:

Tabla 5. Acción/Aventura según la población de referencia.

	PC/consola	**No juega**
Vio acción en el cine, sobre toda la población	40%	12%

	PC/consola	No juega
Vio acción, entre quienes fueron al cine	65%	43%

La primera fila parece mostrar una preferencia de «3 a 5 veces», pero en realidad refleja que los jugadores van más al cine. Entre asistentes la brecha existe, pero ajustada es de +12,6 pp, con un intervalo muy amplio (−8,0 a +33,3), y no alcanza significación.

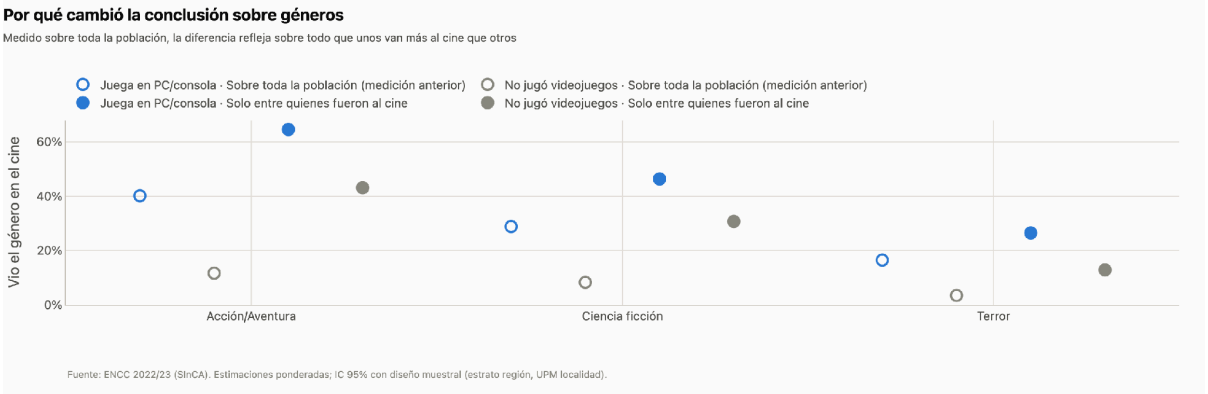


Figura 4. Géneros vistos en el cine: sobre toda la población y entre asistentes. Fuente: ENCC 2022/23, elaboración propia.

5.5 Predicción

Para predecir quién va al cine, el gaming no agrega información a la demografía; el streaming sí. Agregar todas las variables de videojuegos cambia el AUC de la regresión logística en −0,006 (IC −0,043 a +0,034), un intervalo que incluye el cero. Agregar streaming lo sube en +0,048 (IC +0,009 a +0,080). La regresión logística iguala o supera al Random Forest en los cuatro bloques: con estas variables, el patrón es casi lineal.

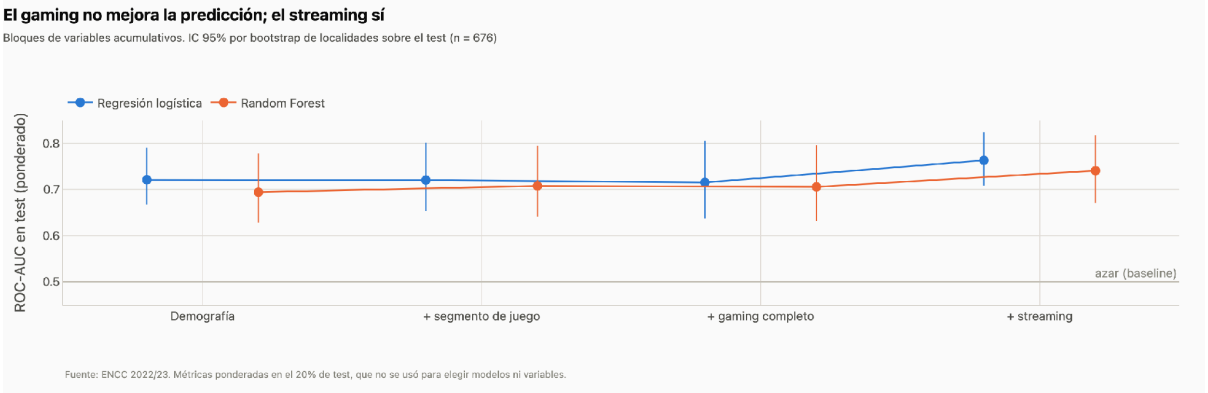


Figura 5. ROC-AUC en el test reservado por bloque de variables y modelo. Fuente: ENCC 2022/23, elaboración propia.

El modelo final (regresión logística con demografía, gaming y streaming; umbral 0,33) es un clasificador moderado:

Tabla 6. Métricas del modelo final en el test reservado (ponderadas).

Métrica	Valor
ROC-AUC	0,76 (IC 0,71–0,82)
Recall	68%
Precisión	56%
Exactitud	67% (el baseline «nunca va» ya logra 62%)
Matriz de confusión (casos sin ponderar)	VN 299 · FP 149 · FN 56 · VP 172

El modelo sirve para ordenar a las personas por propensión, no para decidir caso por caso. Las variables más importantes, medidas por permutación, son la edad, el nivel educativo, la frecuencia de uso de plataformas pagas, ver acción/aventura en streaming y el tamaño de la localidad. La primera variable de videojuegos (shooters) aparece recién en el puesto 8.

5.6 Contexto de mercado

Las cinco adaptaciones de videojuegos estrenadas en 2022–2023 vendieron 6,2 millones de entradas, el 8,3% del total. Solo dos se estrenaron antes del trabajo de campo de la encuesta.

Tabla 7. Adaptaciones de videojuegos estrenadas en 2022–2023.

Título	Estreno	Entradas	Respecto de la ENCC
Uncharted	17/02/2022	548.429	Anterior
Sonic 2	07/04/2022	1.295.715	Anterior
Super Mario Bros.	05/04/2023	3.015.606	Posterior
Gran Turismo	24/08/2023	118.335	Posterior
Five Nights at Freddy's	26/10/2023	1.202.673	Posterior

Super Mario Bros. fue el cuarto estreno más visto entre los 899, pero se estrenó después de la encuesta y no pudo influir en las respuestas. Estos datos describen el mercado y no se vinculan persona a persona con la ENCC.

6. Discusión y conclusiones

Jugar en PC o consola está asociado a ir más al cine, y la asociación no se explica solo por la edad. Sin embargo, cuando el objetivo es predecir, esa información resulta casi redundante con la edad y la educación.

Tabla 8. Veredicto por hipótesis.

	Hipótesis	**Veredicto**	**Evidencia**
H1	Van más al cine, a igual edad y perfil	Se sostiene	+16,5 pp (IC 9,9–23,1); OR 2,23–2,56 en 8 variantes
H2	Prefieren Acción, Ciencia ficción y Terror	No se sostiene	0 de 10 géneros significativos tras Holm
H3	Una campaña dirigida a ellos rinde más	No evaluable	No hay datos de exposición ni de respuesta a publicidad
+	El gaming ayuda a predecir la asistencia	No	ΔAUC −0,006 (IC incluye 0); streaming +0,048

Las dos conclusiones principales no se contradicen. La regresión logística responde si jugar se asocia con ir al cine *a igualdad del resto*, y la respuesta es sí. El modelo predictivo responde si saber que alguien juega *agrega información* a lo que ya se conoce. Como los jugadores son mayormente jóvenes y con más educación, la mayor parte de esa información ya está contenida en la demografía.

En términos prácticos, el público de cine se identifica mejor por la edad y el consumo de streaming que por los hábitos de juego. La hipótesis de una preferencia por géneros específicos, que motivaba la idea de campañas dirigidas, no tiene respaldo una vez que se mide correctamente.

7. Limitaciones

- **Asociación, no causalidad.** La encuesta es transversal. Puede haber variables no medidas, como el ingreso del hogar o el interés general por el entretenimiento, que expliquen parte de la diferencia.
- **Diseño muestral aproximado.** La base no incluye radios censales, por lo que la varianza se calcula con región y localidad. CABA tiene una sola localidad, y allí se usan las personas como unidades de varianza.

- **Pocos jugadores mayores.** Hay solo 35 jugadores de PC/consola mayores de 50 años, por lo que la comparación en esas edades es imprecisa. La variante «solo 13 a 49 años» confirma el resultado donde sí hay datos.
- **Medidas de género distintas.** La ENCC registra cómo la persona clasifica lo que vio; TMDB, el catálogo. En TMDB una película tiene varios géneros, por lo que las participaciones por género en taquilla suman 245%.
- **Fuente INCAA derivada.** El export crudo original no está disponible y la fecha de corte de los acumulados de entradas no está documentada.
- **Predicción retrospectiva.** El modelo clasifica una asistencia que ya ocurrió y no mide la respuesta a publicidad. Por eso H3 no es evaluable y se retiró el simulador de retorno de campañas de la primera versión: sus supuestos (CPM, conversión) no estaban medidos.

8. Reproducibilidad

Todo el análisis se regenera con un único comando (python run_all.py) desde el repositorio, en unos tres minutos. Las cifras de este informe, de la presentación y del tablero interactivo salen de las tablas generadas por ese proceso. Toda partición, validación cruzada y bootstrap usa la semilla fija 20221101, y las versiones de las librerías están fijadas en requirements.txt (Python 3.12, pandas, statsmodels, scikit-learn, plotly y streamlit). Además de las tablas y figuras, el proyecto incluye un tablero interactivo en Streamlit y una página de storytelling autocontenida.

Referencias

Secretaría de Cultura de la Nación, Sistema de Información Cultural de la Argentina (SInCA). (2023). *Encuesta Nacional de Consumos Culturales 2022/23: microdatos, cuestionario, metodología y diseño muestral*. https://datos.cultura.gob.ar/dataset/251c2ac2-e670-451c-9dbf-a4212af225b5 (consultado el 2 de noviembre de 2026).

Instituto Nacional de Cine y Artes Audiovisuales (INCAA). *Cantidad de espectadores por película estrenada*, estrenos 2022 y 2023. https://www.incaa.gob.ar/cantidad-de-espectadores-por-pelicula-estrenada/

The Movie Database (TMDB). *API v3*. https://developer.themoviedb.org/docs

Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics, 6*(2), 65–70.

Lumley, T. (2010). *Complex Surveys: A Guide to Analysis Using R*. Wiley.